

PRD - Project Requirements Document

Grokpi - OpenAI-compatible gateway untuk Grok/xAI, Admin Console, token pool, API key, usage, cache, image, video, dan TTS.

1. Overview

Grokpi adalah gateway AI self-hosted yang menyediakan API kompatibel OpenAI untuk workload Grok/xAI: chat/LLM, text-to-image, image edit, text-to-video, image-to-video, dan text-to-speech. Sistem ini menjadi satu pintu bagi aplikasi MASJAVAS atau client lain agar tidak perlu langsung mengelola token upstream, retry, quota, cache media, atau perbedaan format response dari provider.

Masalah utama yang diselesaikan adalah kebutuhan akses model Grok yang stabil, terukur, dan mudah diintegrasikan melalui endpoint standar seperti `/v1/models`, `/v1/chat/completions`, `/v1/audio/speech`, dan async video generation. Grokpi juga menyediakan Admin Console untuk mengelola token pool, API key, whitelist model, usage log, konfigurasi runtime, dan cache file video.

Tujuan utama produk adalah menyediakan platform gateway AI yang ringan untuk self-hosting di VPS/server, aman untuk produksi kecil-menengah, dan tetap nyaman dipakai oleh developer melalui format OpenAI-compatible.

2. Requirements

- **Aksesibilitas:** API harus dapat diakses melalui HTTP/HTTPS, sementara Admin Console tersedia melalui browser di endpoint aplikasi yang sama.
- **Kompatibilitas API:** Endpoint utama wajib mengikuti pola OpenAI-compatible agar mudah dipakai oleh SDK/client umum.
- **Auth Terpisah:** Admin Console memakai `app_key`, sedangkan endpoint `/v1/*` memakai API key per aplikasi/client.
- **Token Pool:** Sistem harus dapat mengelola token upstream Grok/xAI dalam pool Basic dan Super.
- **Quota dan Rate Limit:** API key dan token harus memiliki batas rate limit, daily limit, quota chat/image/video, serta pencatatan penggunaan.
- **Media Generation:** Sistem harus mendukung text-to-image, image edit, video generation sync/async, cache video, dan TTS.
- **Observability:** Admin harus dapat melihat health, status sistem, usage log, quota/token stats, dan cache stats.
- **Deployment:** Sistem harus dapat dijalankan sebagai single Go binary, Docker Compose, SQLite default, dan opsi PostgreSQL.
- **Security:** Rahasia seperti upstream token, API key, cookie, dan `config.toml` tidak boleh terekspos di log, dokumen publik, atau frontend client.

3. Core Features

1. **OpenAI-Compatible Gateway:** `/v1/models`, `/v1/chat/completions`, SSE stream, chat, reasoning, tool calling, image, dan video sync.
2. **Admin Console:** login berbasis `app_key`, dashboard status, token, quota, usage, health, dan settings runtime.
3. **Token Pool Management:** batch import, edit, delete, replace, reset usage, sync quota, refresh, revalidate, fallback token, dan video capability test.


4. **API Key Management:** create, list, update, delete, regenerate, whitelist model, rate limit, daily limit, expiry, dan usage tracking.
5. **Image, Video, dan TTS:** image generate/edit, video sync/async, image-to-video, dan speech generation OpenAI-style.
6. **Async Video Job Manager:** status `queued`, `processing`, `completed`, `failed`, atau `timeout`, plus polling dan result endpoint.
7. **Usage, Cache, dan File Serving:** usage log, cache stats, delete/clear cache, dan public video serving via `/api/files/video/{name}`.

4. User Flow


1. **Setup Admin:** operator deploy Grokpi, mengatur `config.toml`, lalu login ke Admin Console.
2. **Setup Token dan API Key:** admin menambahkan token Basic/Super, sinkron quota, lalu membuat API key client.
3. **Integrasi Client:** aplikasi menyimpan base URL dan API key di environment server-side, lalu memanggil `GET /v1/models`.
4. **Request AI:** client mengirim chat, image, video, atau TTS; Grokpi validasi auth, limit, payload, memilih token, dan meneruskan ke upstream.
5. **Monitoring:** admin memantau usage, quota, token health, API key usage, cache, dan status video job.

5. Architecture


MERMAID FLOWCHART - HIGH-LEVEL ARCHITECTURE




MERMAID SEQUENCE - REQUEST CHAT/IMAGE/VIDEO SYNC



MERMAID SEQUENCE - ASYNC VIDEO FLOW



6. Database Schema



Tabel	Deskripsi
api_keys	API key client, status, whitelist model, rate limit, daily limit, usage counter, dan expiry.
tokens	Token upstream Grok/xAI beserta pool, status, quota chat/image/video, cooldown, refresh metadata, dan video capability.
usage_logs	Log request API untuk observability: model, endpoint, status, durasi, token usage, API key, dan token upstream.
video_generation_jobs	Lifecycle job video async: queued/processing/completed/failed/timeout, metadata request, URL hasil, dan error.
config_entries	Konfigurasi runtime yang disimpan di database melalui Admin Console.

7. Design & Technical Constraints

- 1. **High-Level Technology:** backend Go 1.24+, chi, GORM, SQLite default, opsi PostgreSQL; frontend Next.js 15, React 19, TypeScript, TanStack Query; build produksi sebagai single Go binary dengan web app embedded.
- 2. **API Compatibility:** endpoint `/v1/*` harus mempertahankan response OpenAI-compatible, error code stabil, dan field custom `image_config` / `video_config`.

3. **Security Rules:** admin auth dan API auth dipisah, API key disamarkan, upstream token tidak bocor, public deployment memakai HTTPS/reverse proxy.
4. **Reliability and Quota:** token selection memperhitungkan pool, model availability, quota, status, cooldown, priority, dan fallback.
5. **Observability:** setiap request gateway dicatat tanpa rahasia; Admin Console menampilkan sistem, usage, token health, quota, dan cache.
6. **Frontend Design:** Admin Console bersifat operasional, padat, mudah discan, dan fokus pada tindakan admin seperti create key, update token, sync quota, clear cache, dan review usage.
7. **Operational Constraints:** target ringan 2 vCPU/2 GB RAM, SQLite untuk single-node, PostgreSQL untuk skala lebih besar, backup `data/` dan `config.toml`, serta cache video yang mudah dibersihkan.